

Cap 3: Bayesian Inference and INLA

Estadística e Inferencia Bayesiana

Estadística clásica – Probabilidad frecuentista

Estadística bayesiana – Distribuciones de probabilidad para determinar la incertidumbre de un modelo.

Se utiliza el **Teorema de Bayes**. $\pi(\theta|\mathbf{y}) = \frac{\pi(\mathbf{y}, \theta)}{\pi(\mathbf{y})} = \frac{\pi(\mathbf{y}|\theta)\pi(\theta)}{\int \pi(\mathbf{y}|\theta)\pi(\theta)d\theta}.$

Distribución posterior de θ (parámetros de la distribución)

Para la **inferencia bayesiana** se requiere especificar una **prior** (“creencia inicial”) previamente, que se representa como una distribución de probabilidad.

Se calcula una **verosimilitud**, que se basa en la distribución de probabilidad de los datos condicionada a los valores de los parámetros, y describe la probabilidad de observar los datos que se conocen dados los parámetros de los modelos.

Algunos métodos para calcular distribuciones posteriores son demandantes de muchos **recursos computacionales** (ej. **MCMC**)

Inferencia bayesiana con MCMC

Métodos de Monte Carlo de cadenas de Markov. Generan una muestra de valores de una cadena de Markov convergente: cuya distribución estacionaria es la distribución posterior ($\pi(\boldsymbol{\theta}|\mathbf{y})$)

$$\{\boldsymbol{\theta}^{(g)}, g = 1, \dots, G\}$$

usar la media muestral para estimar la media posterior

$$\widehat{E(\theta_i|\mathbf{y})} = \frac{1}{G} \sum_{i=1}^G \theta_i^{(g)},$$

usar la varianza muestral para estimar la varianza

$$\widehat{Var(\theta_i|\mathbf{y})} = \frac{1}{G-1} \sum_{i=1}^G (\theta_i^{(g)} - \widehat{E(\theta_i|\mathbf{y})})^2.$$

INLA - Integrated nested Laplace approximation

(Aproximación Integrada de Laplace)

Se utiliza para realizar inferencias en modelos bayesianos, especialmente modelos jerárquicos, espaciales y espacio-temporales (**Modelos Gaussianos**) debido a su eficiencia computacional.

Utiliza una combinación de aproximaciones analíticas e integración numérica para obtener aproximaciones de distribuciones posteriores de los parámetros, siendo mucho más rápida que los modelos de Cadenas de Markov con Mote Carlo.

Para utilizarlo en R se utiliza el paquete “R-INLA”, pero previo a su instalación se debe instalar la última versión de R (<https://cran.r-project.org/bin/windows/base/>). El paquete “R-INLA” se descarga desde web, mediante el siguiente comando:

```
install.packages("INLA", repos = "https://inla.r-inla-download.org/R/stable", dep = TRUE)
```

INLA – Modelos Gaussianos latentes

Los datos u observaciones pertenecen a la familia de las exponenciales (e.g. Gaussiana, Poisson, Binomial, ...).

$$y_i | \mathbf{x}, \boldsymbol{\theta} \sim \pi(y_i | x_i, \boldsymbol{\theta}) \quad i = 1, \dots, n \quad \mu_i = g^{-1}(\eta_i) \quad (\text{media de la distribución})$$

Se tiene el campo Gaussiano latente, donde los parámetros (\mathbf{x}) siguen una distribución Gaussiana

$$\mathbf{x} | \boldsymbol{\theta} \sim N(\boldsymbol{\mu}(\boldsymbol{\theta}), \mathbf{Q}(\boldsymbol{\theta})^{-1})$$

Además, dicha distribución depende de los hiperparámetros ($\boldsymbol{\theta}$) (no necesariamente Gaussiana)

$$\boldsymbol{\theta} \sim \pi(\boldsymbol{\theta})$$

Se tiene un predictor línea que da cuenta de los efectos de las covariables.

$$\eta_i = \alpha + \sum_{k=1}^{n_\beta} \beta_k z_{ki} + \sum_{j=1}^{n_f} f^{(j)}(u_{ji})$$

Intercepto

Efecto de las covariables

Efectos aleatorios definidos en términos de algunas covariables

$$\pi(y_i | x_i, \boldsymbol{\theta})$$

Distribución de probabilidad de los datos dado el vector de parámetros (Función de verosimilitud)

INLA – Modelos Gaussianos latentes

Se calculan los marginales posteriores del campo Gaussiano latente y de los hiperparámetros

$$\pi(x_i|\mathbf{y}) = \int \pi(x_i|\boldsymbol{\theta}, \mathbf{y})\pi(\boldsymbol{\theta}|\mathbf{y})d\boldsymbol{\theta}, \quad \pi(\theta_j|\mathbf{y}) = \int \pi(\boldsymbol{\theta}|\mathbf{y})d\boldsymbol{\theta}_{-j}$$

Se utiliza esta forma para construir las aproximaciones anidadas

$$\tilde{\pi}(x_i|\mathbf{y}) = \int \tilde{\pi}(x_i|\boldsymbol{\theta}, \mathbf{y})\tilde{\pi}(\boldsymbol{\theta}|\mathbf{y})d\boldsymbol{\theta}, \quad \tilde{\pi}(\theta_j|\mathbf{y}) = \int \tilde{\pi}(\boldsymbol{\theta}|\mathbf{y})d\boldsymbol{\theta}_{-j}$$

Esta aproximación puede integrarse numéricamente con respecto a los hiperparámetros

$$\tilde{\pi}(x_i|\mathbf{y}) = \sum_k \tilde{\pi}(x_i|\boldsymbol{\theta}_k, \mathbf{y})\tilde{\pi}(\boldsymbol{\theta}_k|\mathbf{y}) \times \Delta_k$$

$$\tilde{\pi}(\theta_j|\mathbf{y}) = \sum_l \tilde{\pi}(\boldsymbol{\theta}_l^*|\mathbf{y}) \times \Delta_l^*$$

R-INLA

0. Identificar las distribuciones y el predictor lineal

$$Y_i | \eta_i, \sigma^2 \sim N(\eta_i, \sigma^2), i = 1, \dots, n \quad \eta_i = \beta_0 + \beta_1 \times x_{1i} + \beta_2 \times x_{2i} + u_i, u_i \sim N(0, \sigma_u^2)$$

1. Escribir el predictor lineal como una fórmula en R

```
formula <- y ~ x1 + x2 + f(id, model = "iid")
```

iid: nombre del modelo

x1, x2 covariables

id: Vector indicador que especifica el elemento de los efectos aleatorios

2. Llamar a la función inla()

```
res <- inla(formula, family = "gaussian", data = d)
```

names(inla.models())\$likelihood: lista de posibles alternativas de familias

inla.doc("nombredefamilia"): detalles sobre familias individuales

names(inla.models())\$prior: lista con las opciones de cada una de las priors

inla.doc("nombredeprior"): documentación sobre una prior específica

Los priors se pueden especificar o dejar en default (que sería una distribución gaussiana de promedio 0 y precisión 0).

```
prior.fixed <- list(mean.intercept = <>, prec.intercept = <>, mean = <>, prec = <>)
```

```
res <- inla(formula, data = d, control.fixed = prior.fixed)
```

R-INLA - Ejemplo de ajuste de un Modelo

Ejemplo: teniendo como información el número de operaciones y muertes en 12 hospitales, el objetivo es evaluar el desempeño de cada hospital con respecto a las tasas de mortalidad quirúrgica.

1. El modelo asume una probabilidad binomial para el número de muertes en cada hospital con una tasa de mortalidad p_i

$$Y_i \sim \text{Binomial}(n_i, p_i), \quad i = 1, \dots, 12.$$

2. El modelo también supone que las tasas de mortalidad entre hospitales son similares y especifica un modelo de efectos aleatorios para las verdaderas tasas de mortalidad p_i

$$\text{logit}(p_i) = \alpha + u_i, \quad u_i \sim N(0, \sigma^2).$$

3. Se especifica una prior no informativa para α con una tasa de mortalidad logística poblacional

$$\alpha \sim N(0, 1/\tau), \quad \tau = 0.$$

Surg

##	n	r	hospital
## 1	47	0	A
## 2	148	18	B
## 3	119	8	C
## 4	810	46	D
## 5	211	8	E
## 6	196	13	F
## 7	148	9	G
## 8	215	31	H
## 9	207	14	I
## 10	97	8	J
## 11	256	29	K
## 12	360	24	L

R-INLA - Ejemplo de ajuste de un Modelo

Ejemplo: teniendo como información el número de operaciones y muertes en 12 hospitales, el objetivo es evaluar el desempeño de cada hospital con respecto a las tasas de mortalidad quirúrgica.

4. El prior predeterminado de la precisión de los efectos aleatorios u_i es
- $$1/\sigma^2 \sim \text{Gamma}(1, 5 \times 10^{-5})$$

5. Este se puede cambiar configurando un Prior de Complejidad Penalizada en la desviación estándar σ . Por ejemplo, podemos especificar que la probabilidad de que σ sea mayor que 1 es menor o igual a 0.01. Este prior se especifica como

```
prior.prec <- list(prec = list(prior = "pc.prec", param = c(1, 0.01)))
```

6. El modelo sería escrito en R como

```
formula <- r ~ f(hospital, model = "iid", hyper = prior.prec)
```

7. Luego, llamamos a `inla()`

```
res <- inla(formula, data = Surg, family = "binomial", Ntrials = n,  
control.predictor = list(compute = TRUE), control.compute = list(dic = TRUE))
```

Surg

##		n	r	hospital
##	1	47	0	A
##	2	148	18	B
##	3	119	8	C
##	4	810	46	D
##	5	211	8	E
##	6	196	13	F
##	7	148	9	G
##	8	215	31	H
##	9	207	14	I
##	10	97	8	J
##	11	256	29	K
##	12	360	24	L

R-INLA – Visualización de resultados

Ejemplo: teniendo como información el número de operaciones y muertes en 12 hospitales, el objetivo es evaluar el desempeño de cada hospital con respecto a las tasas de mortalidad quirúrgica.

Para obtener resumen del objeto, el DIC del modelo, resúmenes de objetos fijos, efectos aleatorios e hiperparámetros se obtienen, respectivamente, con:

summary(res)

res\$dic\$dic

res\$summary.fixed

res\$summary.random

res\$summary.hyperpar

DIC=Devianza del modelo + 2×Desviación estándar de la devianza posterior

```
## Fixed effects:
##              mean   sd 0.025quant 0.5quant 0.975quant
## (Intercept) -2.545 0.14      -2.838   -2.539    -2.281
##              mode kld
## (Intercept) -2.53    0
##
## Random effects:
## Name      Model
## hospital  IID model
##
## Model hyperparameters:
##              mean   sd 0.025quant 0.5quant
## Precision for hospital 12.04 18.30      2.366    8.292
##              0.975quant mode
## Precision for hospital      41.86 5.337
##
## Expected number of effective parameters(std dev): 7.257(1.703)
## Number of equivalent replicates : 1.654
##
## Deviance Information Criterion (DIC) .....: 74.93
## Deviance Information Criterion (DIC, saturated) ....: 25.16
## Effective number of parameters .....: 8.173
##
## Marginal log-Likelihood: -41.16
```

R-INLA – Visualización de resultados


```
res$summary.fitted.values
```

```
##              mean      sd 0.025quant
## fitted.Predictor.01 0.05667 0.01872   0.02284
## fitted.Predictor.02 0.10224 0.02132   0.06685
## fitted.Predictor.03 0.07220 0.01695   0.04229
## fitted.Predictor.04 0.06011 0.00787   0.04540
## fitted.Predictor.05 0.05410 0.01298   0.03041
## fitted.Predictor.06 0.07057 0.01438   0.04465
## fitted.Predictor.07 0.06838 0.01545   0.04061
## fitted.Predictor.08 0.12140 0.02205   0.08256
## fitted.Predictor.09 0.07123 0.01420   0.04563
## fitted.Predictor.10 0.07941 0.01918   0.04674
## fitted.Predictor.11 0.10160 0.01723   0.07156
## fitted.Predictor.12 0.06951 0.01152   0.04836
##              0.5quant 0.975quant      mode
## fitted.Predictor.01 0.05595   0.09579 0.05534
## fitted.Predictor.02 0.10007   0.14968 0.09535
## fitted.Predictor.03 0.07103   0.10923 0.06920
## fitted.Predictor.04 0.05986   0.07621 0.05936
## fitted.Predictor.05 0.05357   0.08088 0.05244
## fitted.Predictor.06 0.06978   0.10128 0.06844
## fitted.Predictor.07 0.06752   0.10147 0.06620
## fitted.Predictor.08 0.12004   0.16822 0.11740
## fitted.Predictor.09 0.07044   0.10153 0.06909
## fitted.Predictor.10 0.07759   0.12256 0.07448
## fitted.Predictor.11 0.10036   0.13865 0.09777
## fitted.Predictor.12 0.06901   0.09360 0.06811
```

Se obtienen las tasas de mortalidad predichas para cada hospital con **res\$summary.fitted.values**.

La columna “**mean**” muestra que los hospitales 2, 8 y 11 son los que tienen las medias posteriores más altas de las tasas de mortalidad.

Las columnas "Cuantil 2.5%" y "Cuantil 97.5%" contienen los límites inferior y superior de los intervalos creíbles del 95% de las tasas de mortalidad y proporcionan medidas de incertidumbre.



R-INLA – Transformación marginal

Si deseamos obtener una transformación de la marginal, podemos usar **inla.tmarginal()**. Por ejemplo, si queremos obtener la varianza del efecto aleatorio u_i , podemos obtener la marginal de la precisión τ y luego aplicar la función inversa.

```
marg.variance <- inla.tmarginal(function(x) 1/x, res$marginals.hyperpar$"Precision for hospital")
```

También podemos utilizar **inla.zmarginal()** para obtener estadísticas resumidas de la marginal.

```
inla.zmarginal(marg.variance)
```

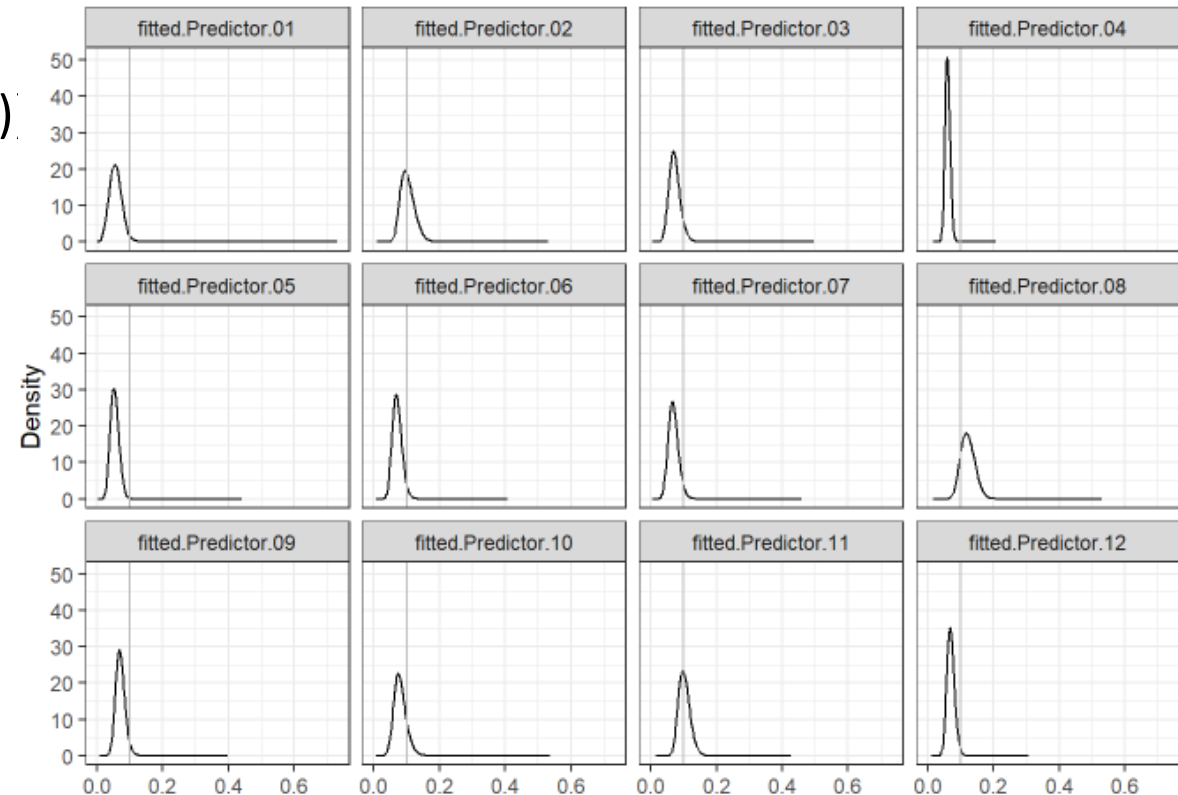
```
## Mean          0.146459
## Stdev         0.106093
## Quantile 0.025 0.0236223
## Quantile 0.25  0.075129
## Quantile 0.5   0.120269
## Quantile 0.75  0.1868
## Quantile 0.975 0.421436
```

R-INLA – Tasas de mortalidad posteriores

En este ejemplo, deseamos evaluar el rendimiento de los hospitales examinando las tasas de mortalidad. **res\$marginals.fitted.values** es una lista que contiene las tasas de mortalidad posteriores de cada uno de los hospitales.

Podemos representar gráficamente estas posteriores construyendo un marco de datos (**marginals**) a partir de la lista **res\$marginals.fitted.values** y agregando una columna hospital que denote el hospital.

```
list_marginals <- res$marginals.fitted.values  
marginals <- data.frame(do.call(rbind, list_marginals))  
marginals$hospital <- rep(names(list_marginals),  
  times = sapply(list_marginals, nrow))
```



R-INLA – Probabilidad de excedencia

También podemos calcular las probabilidades de que las tasas de mortalidad sean **mayores que un valor umbral dado**. Estas probabilidades se conocen **como probabilidades de excedencia** y se expresan como $P(\pi > c)$. Se puede calcular con la función **inla.pmarginal()**, pasando como argumentos la distribución marginal de p_1 y el valor umbral c :

```
marg <- res$marginals.fitted.values[[1]]  
1 - inla.pmarginal(q = 0.1, marginal = marg)  
## [1] 0.01644
```

Podemos calcular las probabilidades de que las tasas de mortalidad sean mayores que 0.1 para todos los hospitales usando la función **sapply()**, pasando como argumentos la lista con todas las marginales (**res\$marginals.fitted.values**) y la función para calcular las probabilidades de **excedencia** (**1 - inla.pmarginal()**). **sapply()** devuelve un vector del mismo largo que la lista **res\$marginals.fitted.values**, con valores iguales al resultado de aplicar la **función 1 - inla.pmarginal()** a cada uno de los elementos de la lista de marginales.

```
## fitted.Predictor.01 fitted.Predictor.02  
## 1.644e-02 5.001e-01  
## fitted.Predictor.03 fitted.Predictor.04  
## 5.925e-02 4.353e-06  
## fitted.Predictor.05 fitted.Predictor.06  
## 7.952e-04 2.901e-02  
## fitted.Predictor.07 fitted.Predictor.08  
## 2.919e-02 8.301e-01  
## fitted.Predictor.09 fitted.Predictor.10  
## 2.999e-02 1.357e-01  
## fitted.Predictor.11 fitted.Predictor.12  
## 5.070e-01 7.982e-03
```

Ejemplos en epidemiología

- Shaddick, Thomas y Green (2018) producen estimaciones globales de la contaminación atmosférica por partículas finas.

<https://academic.oup.com/jrsssc/article/67/1/231/7058389?login=false#396910509>

- Moraga et al. (2015) predicen la prevalencia de filariasis linfática en África subsahariana

<https://parasitesandvectors.biomedcentral.com/articles/10.1186/s13071-015-1166-x>

- Osgood-Zimmerman et al. (2018) mapean el fallo en el crecimiento infantil en África.

<https://www.nature.com/articles/nature25760>

Video: <https://www.youtube.com/watch?v=Tdb5EPczE9E&t=4082s>

Paquete R-INLA – Especificación de priors

Se puede ver escribiendo `names(inla.models())$prior`, y una lista con las opciones de cada una de las priors se puede ver con `inla.models()$prior`. La documentación sobre una prior específica se puede ver con `inla.doc("nombredeprior")`. Los valores de estas priors se pueden cambiar en el argumento `control.fixed` de `inla()` al asignar una lista con la media y la precisión de las distribuciones gaussianas.

```
prior.fixed <- list(mean.intercept = <>, prec.intercept = <>, mean = <>, prec = <>)
```

```
res <- inla(formula, data = d, control.fixed = prior.fixed)
```

```
prior.prec <- list(initial = <>, prior = <>, param = <>, fixed = <>)
```

```
prior <- list(prec = prior.prec)
```

`hyper` acepta una lista con nombres iguales a cada uno de los hiperparámetros, y valores iguales a una lista con la especificación de las priors. Específicamente, la lista contiene los siguientes valores:

`initial`: valor inicial del hiperparámetro (buenos valores iniciales pueden acelerar el proceso de inferencia).

`prior`: nombre de la distribución prior (por ejemplo, "iid", "bym2").

`param`: vector con los valores de los parámetros de la distribución prior.

`fixed`: variable booleana que indica si el hiperparámetro es un valor fijo.

INLA-package

```
install.packages("INLA",  
  repos = "https://inla.r-inla-download.org/R/stable",  
  dep = TRUE)  
  
library(INLA)
```

Model

Observaciones siguen distribución normal

$$Y_i | \eta_i, \sigma^2 \sim N(\eta_i, \sigma^2), i = 1, \dots, n$$

$$\eta_i = \beta_0 + \beta_1 \times x_{1i} + \beta_2 \times x_{2i} + u_i, u_i \sim N(0, \sigma_u^2)$$

covariables

efectos aleatorios

1 Write the linear predictor as a formula object in R

resultado

cov2

Modelo es similar a la regresión lineal lm()

```
formula <- y ~ x1 + x2 + f(id, model = "iid")
```

cov1

Índices y modelo de los efectos aleatorios

Random effects specified with `f()`. First argument `id` is an index vector that specifies the element of the random effect that applies to each observation, second argument model name

2 Call the function `inla()`

```
res <- inla(formula, family = "gaussian", data = d)
```

Paquete R-INLA – Ejemplo de especificación y ajuste de un Modelo usando R-INLA

iid, es uno de los modelos a probar. Más info con **inla.doc("iid")**. La fórmula del modelo se guardará como **formula**.

Con el comando **res** se guardarán los resúmenes y densidades marginales posteriores, usando el comando **inla** para especificar los datos, familia de la distribución de probabilidad y numero de intentos.

```
formula <- r ~ f(hospital, model = "iid", hyper = prior.prec)
```

```
res <- inla(formula, data = Surg, family = "binomial", Ntrials = n, control.predictor =  
list(compute = TRUE), control.compute = list(dic = TRUE))
```

Paquete R-INLA

- La aproximación laplaciana simplificada (que es la opción predeterminada en el paquete R-INLA) tiene un menor costo y remedia de manera satisfactoria las inexactitudes en la ubicación y asimetría de la aproximación gaussiana.

Cap 3: Inferencia Bayesiana e INLA

- Mejoran la predicción y estimación de los modelos.
- Recordemos probabilidades.

$y=(y_1,y_2,...,y_n)$: Datos observados

θ : Vector de parámetros desconocidos

$\pi(y|\theta)$: Distribución de probabilidad de los datos dado el vector
(Función de verosimilitud)

$\pi(\theta|y)$: Distribución de probabilidad del vector dados los datos
(Distribución posterior)

Verosimilitud marginal de los datos observados

Se asume constante de escala.

Distribución de probabilidad de los datos y el vector

Distribución de probabilidad del vector

$$\pi(\theta|y) = \frac{\pi(y, \theta)}{\pi(y)} = \frac{\pi(y|\theta)\pi(\theta)}{\int \pi(y|\theta)\pi(\theta)d\theta}.$$

The diagram illustrates the derivation of the posterior distribution. It shows the joint distribution $\pi(y, \theta)$ as the product of the likelihood $\pi(y|\theta)$ and the prior $\pi(\theta)$. The posterior $\pi(\theta|y)$ is then obtained by dividing the joint distribution by the marginal likelihood $\pi(y)$, which is the integral of the joint distribution over all possible values of θ .

INLA

$$y_i | \boldsymbol{x}, \boldsymbol{\theta} \sim \pi(y_i | x_i, \boldsymbol{\theta}), \quad i = 1, \dots, n,$$

$$\boldsymbol{x} | \boldsymbol{\theta} \sim N(\boldsymbol{\mu}(\boldsymbol{\theta}), \boldsymbol{Q}(\boldsymbol{\theta})^{-1}),$$

$$\boldsymbol{\theta} \sim \pi(\boldsymbol{\theta}),$$

$$\eta_i = \alpha + \sum_{k=1}^{n_\beta} \beta_k z_{ki} + \sum_{j=1}^{n_f} f^{(j)}(u_{ji}).$$

$y=(y_1,y_2,...,y_n)$: Datos observados

θ : Vector de hiperparámetros

x : Campo gaussiano latente

Paquete R-INLA – Predictor lineal

`install.packages("INLA" , repos = "https://inla.r-inla-download.org/R/stable", dep = TRUE)`

`inla()`, donde especificamos la fórmula, la familia, los datos y otras opciones.

El formato del predictor lineal en R-INLA es similar al de otros modelos lineales como `lm()`

$$Y_i \sim N(\eta_i, \sigma^2), \quad i = 1, \dots, n$$

$$\eta_i = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + u_i$$

donde Y_i es la variable de respuesta, η_i es el predictor lineal, x_1, x_2 son dos variables explicativas, y $u_i \sim N(0, \sigma_u^2)$, la fórmula se escribe como

$$y \sim x_1 + x_2 + f(i, model = "iid")$$

Ten en cuenta que por defecto, la fórmula incluye una intersección (intercepto). Si quisiéramos incluir explícitamente β_0 en la fórmula, necesitaríamos eliminar el intercepto (agregando 0) e incluirlo como un término de covariable (agregando b_0):

$$y \sim 0 + b_0 + x_1 + x_2 + f(i, model = "iid")$$